

Đề xuất nghiên cứu

Xây dựng khung học máy đa nguồn dữ liệu cho ước lượng không gian và dự báo thời gian xâm nhập mặn tại Đồng bằng sông Cửu Long

1. Bối cảnh và tính cấp thiết

Xâm nhập mặn là một trong những thách thức môi trường nghiêm trọng tại Đồng bằng sông Cửu Long (ĐBSCL), đặc biệt trong mùa khô khi dòng chảy thượng nguồn suy giảm, thủy triều tác động mạnh và nhu cầu nước ngọt cho sản xuất nông nghiệp, nuôi trồng thủy sản và sinh hoạt tăng cao. Các đợt xâm nhập mặn lớn trong những năm gần đây cho thấy độ mặn có thể biến động nhanh theo thời gian, khác biệt đáng kể giữa các nhánh sông, và chịu ảnh hưởng đồng thời của điều kiện thủy văn, khí tượng, địa hình, khoảng cách đến biển, mạng lưới sông - kênh và trạng thái bề mặt.

Hệ thống trạm quan trắc cung cấp nguồn dữ liệu trực tiếp và đáng tin cậy, nhưng mật độ trạm không thể phủ kín toàn bộ vùng nghiên cứu. Điều này tạo ra hai nhu cầu liên quan nhưng khác bản chất. Thứ nhất là dự báo thời gian tại các trạm đã có quan trắc, nhằm cảnh báo trước biến động độ mặn trong ngắn hạn. Thứ hai là ước lượng không gian tại các vị trí chưa có trạm, nhằm mở rộng thông tin điểm thành dạng bản đồ hoặc lưới không gian phục vụ quản lý vùng.

Trong bối cảnh đó, các nguồn dữ liệu mở như ERA5-Land, Sentinel-2, DEM và các biến địa không gian có tiềm năng bổ sung cho dữ liệu trạm. Dữ liệu khí tượng - thủy văn phản ánh điều kiện nền của quá trình xâm nhập mặn; ảnh vệ tinh phản ánh đặc trưng bề mặt nước, thực vật và độ ẩm; các biến tĩnh không gian mô tả vị trí tương đối của điểm quan trắc trong hệ thống sông - biển. Tuy nhiên, các nguồn dữ liệu này có bản chất, độ phân giải và mức độ liên quan đến độ mặn khác nhau. Vì vậy, đề tài không hướng đến một mô hình đơn lẻ, mà xây dựng một khung học máy đa nguồn dữ liệu gồm hai nhánh: dự báo thời gian và ước lượng không gian.

2. Khoảng trống nghiên cứu

Các nghiên cứu về xâm nhập mặn thường tập trung vào một trong hai hướng: mô hình chuỗi thời gian tại trạm, hoặc mô hình lập bản đồ dựa trên ảnh vệ tinh và các biến môi trường. Các mô hình chuỗi thời gian như LSTM có khả năng học động học quá khứ và dự báo ngắn hạn tại điểm đã có dữ liệu, nhưng phụ thuộc vào lịch sử độ mặn tại chính trạm đó. Ngược lại, các mô hình không gian như Random Forest, XGBoost, Gaussian Process Regression hoặc Kriging có thể hỗ trợ ước lượng tại vị trí chưa đo, nhưng thường gặp khó khăn khi số trạm huấn luyện ít, quan hệ giữa phổ ảnh vệ tinh và độ mặn không ổn định, hoặc quy trình đánh giá chưa tách bạch giữa dự báo trên trạm cũ và ngoại suy sang trạm mới.

Một vấn đề quan trọng là cần phân biệt rõ bài toán "dự báo thời gian" và "ước lượng không gian". Nếu mô hình được đánh giá bằng cách chia train/test theo thời gian nhưng các trạm trong test đã xuất hiện

trong train, kết quả cao có thể chủ yếu phản ánh khả năng học đặc trưng riêng của trạm, không đảm bảo mô hình sẽ dự đoán tốt tại trạm mới. Đối với mục tiêu lập bản đồ hoặc ước lượng vùng chưa có trạm, cần đánh giá bằng spatial cross-validation, trong đó toàn bộ một nhóm trạm được giữ ngoài tập huấn luyện.

Bên cạnh đó, việc sử dụng độ mặn lịch sử làm feature cho mô hình không gian cần được cân nhắc. Nếu mục tiêu là dự đoán tại vị trí chưa có trạm, các biến như `salinity_lag1` hoặc `salinity_lag2` không có sẵn tại điểm mới và có thể làm mô hình đạt điểm cao trong thực nghiệm nhưng khó ứng dụng thực tế. Vì vậy, trong nhánh không gian của đề tài này, độ mặn quan trắc được xem là nhãn huấn luyện; các feature đầu vào cần là các biến có thể tái tạo trên toàn vùng, bao gồm biến tĩnh không gian, mùa vụ, khí tượng và viễn thám.

3. Mục tiêu nghiên cứu

Mục tiêu tổng quát của đề tài là xây dựng khung học máy đa nguồn dữ liệu cho ước lượng không gian và dự báo thời gian xâm nhập mặn tại ĐBSCL, kết hợp dữ liệu trạm quan trắc với dữ liệu khí tượng, viễn thám và biến địa không gian.

Các mục tiêu cụ thể gồm:

1. Xây dựng bộ dữ liệu đa nguồn gồm độ mặn quan trắc, ERA5-Land, Sentinel-2, tọa độ trạm, DEM và các biến khoảng cách không gian phục vụ bài toán học máy.
2. Phát triển và đánh giá mô hình LSTM cho bài toán dự báo độ mặn trước 7 ngày tại các trạm quan trắc, bao gồm các cấu hình ablation như LSTM chỉ dùng lịch sử mặn, MS-only và MS-LSTM đa nguồn.
3. Phát triển nhánh ước lượng không gian cho các vị trí chưa có trạm, trong đó Ridge/Regression Kriging với nội suy phần dư được xem là hướng chính, còn XGBoost được dùng như baseline học máy phi tuyến.
4. Đề xuất quy trình đánh giá phù hợp cho từng bài toán, bao gồm temporal split cho dự báo thời gian và spatial/spatio-temporal split cho khả năng tổng quát hóa sang trạm mới.

4. Câu hỏi nghiên cứu

Đề tài tập trung vào các câu hỏi sau:

1. Lịch sử độ mặn tại trạm đóng vai trò như thế nào trong dự báo ngắn hạn 7 ngày, và mô hình LSTM có vượt được baseline persistence hay không?
2. Khi không dùng lịch sử độ mặn, các nguồn dữ liệu ngoại sinh như ERA5-Land, Sentinel-2, tọa độ và mùa vụ có đủ sức giải thích biến động độ mặn hay không?
3. Đối với bài toán không gian, các biến có thể tái tạo trên lưới toàn vùng có cho phép ước lượng độ mặn tại trạm chưa từng xuất hiện trong huấn luyện hay không?
4. Mô hình drift-only, mô hình nội suy trực tiếp và mô hình kết hợp drift + residual interpolation khác nhau như thế nào về sai số và khả năng ứng dụng lập bản đồ?
5. Sentinel-2 nên được xem là nguồn thông tin chính hay nguồn phụ trợ trong bài toán ước lượng độ mặn tại ĐBSCL?

5. Phạm vi dữ liệu và tiền xử lý

5.1. Dữ liệu quan trắc độ mặn

Dữ liệu độ mặn được tổng hợp theo trạm và ngày cho giai đoạn 2020-2023. Bộ dữ liệu LSTM hiện có bao gồm 22 trạm với 27.434 station-days từ ngày 2020-01-01 đến 2023-05-31. Trong đó, 10.120 station-days có giá trị độ mặn quan trắc hợp lệ sau kiểm soát chất lượng, tương đương 36,89% lưới ngày-trạm. Cột mục tiêu chỉ sử dụng giá trị quan trắc thật; các giá trị forward-fill ngắn hạn chỉ được dùng làm đầu vào lịch sử cho mô hình thời gian.

Dữ liệu 2025 hiện có một số trạm trùng với hệ thống 2020-2023 và có thể dùng làm external temporal test. Dữ liệu 2024 có tiềm năng lớn cho nhánh không gian vì bao gồm nhiều trạm mới, nhưng hiện chưa có tọa độ xác thực. Do đó, dữ liệu 2024 chỉ nên được đưa vào nhánh không gian sau khi hoàn thiện station master gồm tọa độ, nguồn tọa độ và mức độ tin cậy.

5.2. Dữ liệu khí tượng và viễn thám

ERA5-Land được trích xuất theo ngày cho các trạm, gồm các biến nhiệt độ, mưa, bốc thoát hơi tiềm năng, dòng chảy, gió, áp suất, độ ẩm đất và bức xạ mặt trời. Trong bộ dữ liệu đã xử lý, ERA5-Land có mặt đầy đủ cho 27.434 station-days. Việc trích xuất ERA5-Land cần được báo cáo là trích xuất theo vùng đệm 12 km, không phải lấy mẫu điểm tuyệt đối.

Sentinel-2 được tổng hợp thành composite tháng trước, bao gồm các chỉ số và kênh phổ liên quan đến nước và bề mặt như MNDWI, NDWI, NDVI, B11, B12, SWIR và các tỉ số phổ. Bộ dữ liệu hiện có 902 dòng station-month cho 22 trạm và 41 tháng mục tiêu, không thiếu tháng Sentinel-2 so với lưới ngày. Đối với nhánh không gian, composite Sentinel-2 và ERA5-Land được tái tạo trên lưới dự đoán bằng Google Earth Engine.

5.3. Biến không gian tĩnh

Biến không gian tĩnh bao gồm kinh độ, vĩ độ, DEM, khoảng cách đến sông và khoảng cách đến bờ biển. Các biến này có vai trò quan trọng trong nhánh không gian vì chúng là những thông tin có thể tính cho cả trạm quan trắc lẫn điểm chưa đo. Trong các thí nghiệm ban đầu, nhóm biến static và weather có tương quan với độ mặn cao hơn nhóm spectral khi xét trên toàn bộ ĐBSCL, cho thấy ảnh vệ tinh nên được đặt trong vai trò hỗ trợ thay vì là tín hiệu duy nhất.

6. Phương pháp đề xuất

6.1. Khung tổng thể

Khung đề xuất gồm hai module chính:

- Module A - dự báo thời gian: dự báo độ mặn trước 7 ngày tại các trạm đã có lịch sử quan trắc bằng LSTM và các biến đa nguồn.

- Module B - ước lượng không gian: ước lượng độ mặn tại điểm chưa có trạm bằng các feature có thể tái tạo trên toàn vùng, kết hợp mô hình drift và nội suy phần dư.

Hai module không thay thế nhau mà bổ sung cho nhau. LSTM trả lời câu hỏi: tại trạm này, 7 ngày nữa độ mặn có thể như thế nào? Module không gian trả lời câu hỏi: tại thời điểm hoặc tháng này, ở vị trí chưa có trạm, độ mặn ước lượng là bao nhiêu nếu biết các trạm xung quanh và các biến môi trường?

6.2. Module dự báo thời gian bằng LSTM

Mô hình LSTM sử dụng cửa sổ đầu vào 30 ngày để dự báo trước 7 ngày. Thiết kế thí nghiệm chia theo thời gian: train 2020-2021, validation 2022 và test 2023. Scaler và imputer chỉ được fit trên tập train để tránh rò rỉ dữ liệu.

Các cấu hình chính gồm:

- Persistence baseline: dự báo bằng giá trị độ mặn gần nhất trong cửa sổ đầu vào.
- LSTM-S: LSTM chỉ dùng lịch sử độ mặn, trạng thái quan trắc, tọa độ, mùa vụ và station embedding.
- MS-only: mô hình đa nguồn không dùng lịch sử độ mặn; đầu vào gồm ERA5-Land, Sentinel-2, tọa độ, mùa vụ và station embedding.
- MS-LSTM: mô hình đa nguồn kết hợp lịch sử độ mặn, ERA5-Land và Sentinel-2.

Thiết kế này cho phép tách riêng hai câu hỏi: quá khứ độ mặn mạnh đến đâu trong dự báo ngắn hạn, và dữ liệu ngoại sinh có thể giải thích độ mặn đến mức nào khi không có lịch sử mặn.

6.3. Module ước lượng không gian

Trong nhánh không gian, độ mặn quan trắc chỉ được dùng làm label huấn luyện hoặc làm điểm neo nội suy, không được đưa vào feature của điểm dự đoán nếu điểm đó chưa có trạm. Tập feature ưu tiên gồm:

- static: kinh độ, vĩ độ, DEM, khoảng cách đến sông, khoảng cách đến bờ biển;
- season: biến chu kỳ ngày/tháng/tuần;
- weather: các biến ERA5-Land tổng hợp theo tuần hoặc tháng;
- spectral: MNDWI, NDWI, NDVI, B11, B12 và các tỉ số phổ Sentinel-2;
- quality: chỉ dùng để diagnostic nếu cần, không xem là feature chính khi lập bản đồ.

XGBoost được xem là baseline phi tuyến để kiểm tra khả năng học từ feature đa nguồn. Tuy nhiên, kết quả ban đầu cho thấy XGBoost đạt điểm tốt khi test theo thời gian trên các trạm đã xuất hiện trong train, nhưng suy giảm rõ khi đánh giá trên trạm mới. Vì vậy, hướng chính của đề tài được điều chỉnh sang Ridge/Regression Kriging thực dụng.

Mô hình không gian chính gồm hai thành phần:

1. Drift model: Ridge regression học xu hướng độ mặn theo các biến có thể tái tạo trên lưới. Ridge được chọn vì ổn định với kích thước mẫu nhỏ, giảm overfitting và dễ diễn giải hơn các mô hình cây phức tạp.

2. Residual interpolation: phần dư giữa giá trị quan trắc và dự đoán Ridge tại các trạm neo được nội suy theo không gian, ban đầu bằng IDW. Giá trị cuối cùng tại điểm dự đoán bằng drift + residual.

Cách tiếp cận này tương đương một dạng Regression Kriging/Universal Kriging thực dụng: mô hình hồi quy mô tả xu hướng lớn theo covariates, còn nội suy phần dư bù đắp các sai lệch địa phương mà covariates chưa giải thích hết.

7. Thiết kế thực nghiệm và đánh giá

7.1. Đánh giá module thời gian

Module LSTM được đánh giá trên test 2023 sau khi chọn mô hình bằng validation 2022. Các metric gồm RMSE, MAE và R2. Ngoài metric tổng thể, cần báo cáo theo trạm và theo tháng để phân tích sai số theo không gian và mùa vụ. Persistence baseline bắt buộc được báo cáo để chứng minh mô hình học được thông tin vượt qua giá trị mạn gần nhất.

7.2. Đánh giá module không gian

Module không gian cần có ít nhất ba kiểu split:

- temporal split: train các năm trước, test năm sau trên các trạm đã có trong train; split này giúp so sánh với các pipeline cũ nhưng không đủ chứng minh khả năng dự đoán trạm mới;
- spatial cross-validation: giữ một nhóm trạm ra khỏi train, đánh giá khả năng dự đoán vị trí chưa từng thấy;
- spatio-temporal split: kết hợp giữ trạm mới và năm mới, đây là kịch bản khó nhất và gần với ngoại suy thực tế.

Với bài toán lập bản đồ tại một tháng hiện tại, residual interpolation được phép dùng quan trắc cùng thời điểm từ các trạm hiện hữu làm điểm neo. Điều này phù hợp với mục tiêu ước lượng không gian: ta không biết độ mạn tại điểm cần dự đoán, nhưng có thể biết độ mạn tại một số trạm quan trắc trong cùng thời điểm. Kịch bản không dùng bất kỳ quan trắc cùng thời điểm nào là bài toán ngoại suy cả không gian lẫn thời gian, khó hơn và không phải mục tiêu chính của module lập bản đồ.

8. Kết quả sơ bộ

8.1. Module LSTM

Trên test 2023 cho horizon 7 ngày, LSTM ensemble đạt RMSE 2,559, MAE 1,852 và R2 0,842 trên 2.774 mẫu test. Trên tập so sánh với persistence, persistence đạt RMSE 3,178 trong khi LSTM ensemble đạt RMSE 2,556. Kết quả này cho thấy LSTM học được động học ngắn hạn tốt hơn baseline gần nhất.

Trong thí nghiệm đa nguồn, MS-only không dùng lịch sử độ mạn đạt RMSE 3,595, MAE 2,814 và R2 0,691. Điều này cho thấy các biến ngoại sinh có khả năng giải thích một phần biến động độ mạn, nhưng vẫn kém hơn mô hình có lịch sử mạn. MS-LSTM ensemble đạt RMSE 2,769, MAE 1,978 và R2

0,817. Các kết quả này ủng hộ việc trình bày MS-only như một ablation quan trọng, không phải mô hình thay thế hoàn toàn cho LSTM có lịch sử mặn trong bài toán dự báo thời gian.

8.2. Module không gian

Với XGBoost, kết quả temporal split khá cao, nhưng spatial/spatio-temporal split thấp hoặc âm. Điều này cho thấy mô hình có thể học tốt các trạm đã thấy, nhưng chưa tổng quát hóa tốt sang trạm mới. Đây không nhất thiết có nghĩa là dữ liệu đa nguồn vô nghĩa, mà cho thấy bài toán không gian với số trạm ít cần cách đánh giá và mô hình phù hợp hơn.

Phân tích tương quan cho thấy nhóm weather và static có median absolute Spearman cao hơn nhóm spectral. Nhóm Sentinel-2 có tương quan tổng thể yếu, nhưng có dấu hiệu hữu ích tại một số tiểu vùng, ví dụ khi tách theo khoảng cách đến biển. Vì vậy, Sentinel-2 nên được xem là nguồn bổ trợ để cải thiện drift model và lập bản đồ, thay vì nguồn duy nhất quyết định độ mặn.

Với Ridge + residual IDW trên bài toán map-ready monthly, kết quả spatial CV sơ bộ đạt R^2 log 0,341, RMSE 5,178 g/L và MAE 3,408 g/L, tốt hơn Ridge-only về RMSE/MAE trong cấu hình tái tạo được trên grid. Bản đồ thử nghiệm tháng 03/2023 đã được tạo từ covariates GEE, có gắn thông tin khoảng cách đến trạm neo để cảnh báo vùng ngoại suy mạnh.

9. Đóng góp dự kiến

Đề tài dự kiến có các đóng góp sau:

1. Xây dựng quy trình tiền xử lý và hợp nhất dữ liệu đa nguồn cho bài toán xâm nhập mặn tại ĐBSCL, gồm độ mặn trạm, ERA5-Land, Sentinel-2 và biến địa không gian.
2. Đánh giá trung thực mô hình LSTM horizon 7 ngày, có baseline persistence, ablation MS-only và báo cáo theo năm test độc lập.
3. Làm rõ sự khác biệt giữa dự báo thời gian tại trạm và ước lượng không gian tại vị trí chưa đo, tránh diễn giải sai kết quả temporal split như bằng chứng cho khả năng lập bản đồ.
4. Đề xuất hướng Regression Kriging/Ridge + residual interpolation như một module không gian phù hợp với bộ dữ liệu trạm thừa và feature có thể tái tạo trên lưới.
5. Cung cấp quy trình tạo covariates trên Google Earth Engine và xuất dự đoán dạng CSV/GeoJSON cho bản đồ tháng.

10. Kế hoạch thực hiện tiếp theo

Trong giai đoạn tiếp theo, đề tài cần ưu tiên bốn việc:

1. Hoàn thiện station master: chuẩn hóa tên trạm, tọa độ, tỉnh/huyện, sông/kênh, DEM, khoảng cách đến sông và khoảng cách đến bờ biển. Riêng dữ liệu 2024 cần bổ sung tọa độ xác thực trước khi dùng cho module không gian.
2. Mở rộng external test: dùng dữ liệu 2025 cho các trạm trùng để kiểm tra khả năng dự báo thời gian ngoài mẫu của LSTM.

3. Nâng cấp residual interpolation: so sánh IDW với Ordinary Kriging/Gaussian Process cho phần dư, nếu số trạm neo và cấu trúc variogram cho phép.
4. Hoàn thiện bản đồ không gian: chạy covariates GEE theo nhiều tháng mùa khô, tạo bản đồ dự đoán và bản đồ độ tin cậy dựa trên khoảng cách đến trạm neo, mật độ trạm và vùng ngoại suy.

11. Giới hạn và rủi ro

Rủi ro lớn nhất của nhánh không gian là số trạm có tọa độ và nhãn độ mặn còn ít so với độ phức tạp không gian của ĐBSCL. Nếu bổ sung dữ liệu 2024 mà không có tọa độ xác thực, mô hình có thể sai nghiêm trọng do gán sai vị trí. Do đó, không nên suy đoán tọa độ trạm khi chưa có nguồn kiểm chứng.

Rủi ro thứ hai là quan hệ giữa Sentinel-2 và độ mặn không mạnh trên toàn vùng. Ảnh vệ tinh vẫn hữu ích để mô tả trạng thái bề mặt nước và phân vùng, nhưng không nên kỳ vọng chỉ dùng spectral indices là có thể dự đoán chính xác độ mặn toàn ĐBSCL.

Rủi ro thứ ba là residual interpolation phụ thuộc vào trạm neo cùng thời điểm. Nếu mục tiêu là tạo bản đồ gần thời gian thực, cần có dữ liệu quan trắc tại một số trạm trong tháng hoặc tuần đó. Nếu không có trạm neo, bài toán chuyển thành dự báo không gian-thời gian hoàn toàn, cần mô hình riêng và kết quả có thể kém ổn định hơn.

12. Kết luận

Đề tài được định hướng như một khung học máy đa nguồn hai nhánh. Nhánh thời gian dùng LSTM để dự báo độ mặn trước 7 ngày tại trạm quan trắc, với kết quả sơ bộ cho thấy mô hình vượt baseline persistence. Nhánh không gian dùng Ridge/Regression Kriging với residual interpolation để ước lượng độ mặn tại vị trí chưa có trạm, trong đó các biến ERA5-Land, Sentinel-2 và biến không gian đóng vai trò drift covariates, còn quan trắc tại trạm hiện hữu đóng vai trò điểm neo.

Cách tiếp cận này phù hợp với mục tiêu "ước lượng không gian và dự báo thời gian" hơn việc ép một mô hình duy nhất giải quyết cả hai bài toán. Nó cũng giúp paper trình bày kết quả một cách trung thực: LSTM mạnh cho dự báo theo thời gian, MS-only cho thấy giá trị của dữ liệu ngoại sinh, XGBoost là baseline cần đối chiếu, và Regression Kriging/Ridge + residual interpolation là hướng chính khả thi cho lập bản đồ xâm nhập mặn trong điều kiện trạm quan trắc còn thưa.